

Identificazione e verifica basati su segnali EEG

Carmelo Scotti

Alessandro Ricchetti

Marco Cappiello

Abstract—

L'EEG è la registrazione delle attività elettriche del cervello che sono il risultato delle attivazioni sinaptiche dei neuroni del cervello. Queste attività elettriche sono il risultato di flussi di corrente ionica causati dall'attivazione sinaptica sincronizzata dei neuroni del cervello [3]. In questo lavoro viene impiegato il dataset BED [15]. I segnali EEG vengono innanzitutto preprocessati: applicazione di filtri passa-alto e passa-basso, trasformata Wavelet discreta e calcolo della densità spettrale di potenza (PSD), mirroring del segnale, dopo il preprocessing, i segnali migliorati vengono utilizzati per addestrare un modello di Deep Learning, in questo lavoro sono stati utilizzati LSTM e GRU. La scelta dei modelli è dovuta al fatto che in letteratura sono stati presentati altri modelli di Deep Learning anziché impiegare una CNN, tra cui le RNN per i sistemi biometrici basati su EEG. In particolare "Long Short-Term Memory" (LSTM) e "Gated Recurrent Unit" (GRU). Successivamente, verranno confrontati i risultati dei due modelli. I risultati mostrano che il modello LSTM presenta risultati leggermente migliori.

I. INTRODUZIONE

Gli approcci biometrici tradizionali includono il riconoscimento delle impronte digitali, del volto, dell'iride, riconoscimento vocale e altri ancora. Utilizzare i segnali EEG nel contesto biometrico presenta vantaggi unici che lo fanno risaltare tra le altre caratteristiche tipiche utilizzate nei sistemi biometrici [1], quali:

- I fattori biometrici come le impronte digitali o l'iride possono essere falsificati o imitati.
- I segnali EEG dipendono dallo stato emotivo e lo stress, infatti cambiano i normali schemi delle onde cerebrali, indipendentemente dall'attività.
- Negli altri tipi di biometria, si può usare un cadavere per autorizzare l'accesso al sistema. Tuttavia, per i sistemi biometrici basati su EEG, un cervello morto non produce segnali.

In base alla frequenza, le onde cerebrali possono essere classificate nelle cinque bande di frequenza seguenti [2]:

- delta (1-4 Hz): è la forma d'onda più lenta e di solito la più alta in ampiezza. La banda delta viene osservata nei neonati e durante il sonno profondo negli adulti;
- theta (4-8 Hz): è stata osservata nei bambini, negli adulti assonnati e durante il richiamo della memoria [16]. L'ampiezza delle onde Theta è normalmente inferiore a 100 μ V;
- alfa (8-12 Hz): è di solito la banda di frequenza dominante e appare durante la relaxed awareness o quando

gli occhi sono chiusi. L'attenzione focalizzata o il rilassamento con gli occhi aperti riducono l'ampiezza della banda Alfa. Queste onde sono normalmente inferiori a 50 μ V;

- beta (12-25 Hz): è associato al pensiero, alla concentrazione attiva e all'attenzione. Inoltre, l'esecuzione di movimenti del corpo o vedere i movimenti del corpo degli altri aumenta la potenza della banda Beta [17]. L'ampiezza delle onde Beta è normalmente inferiore a 30 μ V;
- gamma (25 Hz e oltre): è osservato durante molteplici processi sensoriali [18]. Le bande gamma hanno l'ampiezza più bassa.

Occorre distinguere tra identificazione e verifica dell'utente. Il processo di identificazione si occupa di stabilire chi sia l'utente: la richiesta del presunto utente viene confrontata con tutti i profili disponibili e assegnata all'identità che fornisce la migliore corrispondenza. Il problema dell'identificazione dei soggetti è stato modellato come un problema di classificazione multiclasse con una classe per ciascun partecipante. La verifica consiste nel provare o smentire l'identità dell'utente dichiarata. In questo caso, il modello riceve un'identità individuale e la registrazione del segnale EEG e predice se tale record appartiene all'identità dichiarata.

Tuttavia, i sistemi biometrici basati su EEG hanno il loro svantaggio più evidente nella scomodità del metodo di registrazione di tali segnali. Inoltre, i segnali EEG possono essere contaminati da artefatti indesiderati causati, ad esempio, da attività oculare, muscolare, cardiaca e respiratoria. Per migliorare la qualità del segnale è necessario un preprocessing molto corposo. Il resto del paper è diviso in 5 sezioni. La sezione II illustra lo stato dell'arte. La sezione III riassume l'approccio seguito nel corso del lavoro. La sezione IV fornisce una descrizione dettagliata della sperimentazione applicata, oltre a una breve descrizione del dataset impiegato e alla presentazione dei risultati ottenuti. La sezione V discute in dettaglio i risultati derivanti dalla sperimentazione seguita. La sezione VI riassume le conclusioni e possibili sviluppi futuri.

II. STATO DELL'ARTE

Finora sono stati proposti molti lavori sui metodi biometrici EEG, che includono sia approcci basati su Machine Learning che sul Deep Learning; tuttavia, i classificatori basati su ML sono più comuni in letteratura. [5] Gli attuali sistemi biometrici basati sull'EEG si dividono nei due approcci descritti in precedenza: uno consiste nell'estrarre prima le feature distinguibili e poi utilizzare i metodi tradizionali di

Machine Learning per la classificazione, mentre l'altro consiste nell'utilizzare un approccio end-to-end di Deep Learning; l'importante vantaggio di questo approccio è che non è necessario estrarre esplicitamente le feature, ma il modello stesso ha la capacità di riconoscere le feature nascoste nei dati. [4] Con l'avanzamento dei metodi di Deep Learning, questi approcci hanno trovato rapidamente spazio nella biometria EEG e hanno dimostrato di poter raggiungere una maggiore precisione.

Tipo	Paper	Soggetti	Canali	Accuracy	Architettura	Layers
DL	proposto	21	14	91.70	LSTM	2
	proposto	21	14	91.34	GRU	2
	Sun [6]	109	64	99.58	CNN+LSTM+Dense	10
	Sun [6]	109	32	99.50	CNN+LSTM+Dense	10
	Sun [6]	109	4	94.34	CNN+LSTM+Dense	10
	Wang [7]	109	64	99.97	Graph CNN+Dense	6
	Wilaiprasitporn [8]	32	5	99.10	CNN+LSTM+Dense	8
ML	Singh [9]	109	64	100	KNN	-
	Kaur [10]	109	64	98.16	SVM, Random forest	-
	Fraschini [11]	109	64	96.9	Euclidean distance	-

Fig. 1: Stato dell'arte

III. METODO PROPOSTO

In questo lavoro, l'approccio seguito non comprende l'estrazione manuale di feature poiché per la classificazione sono stati impiegati modelli di Deep Learning.

La fase di preprocessing dei segnali EEG è un passaggio molto importante nella sperimentazione. Senza la fase di preprocessing, potrebbero esserci dati rumorosi e artefatti che possono mascherare feature distintive dei segnali EEG. Quindi, al fine di rimuovere gli artefatti come quelli derivanti da movimenti muscolari, della mandibola o dal battito delle palpebre, i segnali EEG "grezzi" hanno bisogno di essere preprocessati in modo tale da migliorare la qualità del segnale stesso. Il preprocessing consiste nell'effettuare un filtraggio nel dominio delle frequenze, in modo tale da andare ad eliminare il rumore al di sotto o al di sopra di una certa frequenza. Successivamente viene applicata la trasformata Wavelet a 2 livelli. La trasformata Wavelet porta il segnale risultante nel dominio tempo-frequenza. Il metodo di analisi del dominio tempo-frequenza combina le informazioni del dominio del tempo e del dominio delle frequenze dei segnali EEG per l'analisi. Nel frattempo, trasforma i segnali della dimensione temporale e di frequenza unidimensionale in una forma bidimensionale. Questo metodo presenta alcuni vantaggi. In primo luogo, può evitare la perdita di informazioni sulla frequenza durante l'analisi del dominio del tempo e la perdita dei transienti della forma d'onda del segnale durante l'analisi del dominio della frequenza. Inoltre, può estrarre caratteristiche che non possono essere espresse simultaneamente in un singolo dominio, come le informazioni di frequenza contenute in ogni istante. [13] Attualmente, i metodi di analisi nel dominio tempo-frequenza più utilizzati includono la trasformata short-time di Fourier, la trasformata wavelet e la decomposizione dei pacchetti wavelet [12]. Al segnale risultante dalla trasformata Wavelet verrà calcolata la PSD (Power Spectral Density). La funzione nel dominio della frequenza utilizza la tecnologia basata sulla trasformata di Fourier per convertire il segnale EEG in una distribuzione di frequenze. L'analisi nel dominio della frequenza dei segnali EEG utilizza principalmente metodi di analisi come i filtri e

la stima dello spettro di frequenza. La stima dello spettro di potenza è un metodo di analisi che descrive le caratteristiche casuali del segnale EEG nel dominio della frequenza. [13] La densità spettrale di potenza (PSD) definisce la distribuzione della potenza di una serie temporale di segnali con la frequenza ed è una misura del valore quadratico medio di una variabile casuale. La PSD viene utilizzata per indicare la distribuzione della potenza del segnale in ogni punto di frequenza. Sebbene l'energia totale di un segnale casuale sia infinita, la sua potenza media è limitata. Sulla base delle caratteristiche casuali del segnale EEG, è possibile analizzare la densità spettrale di potenza del segnale EEG nel dominio della frequenza ed estrarre le caratteristiche della densità spettrale di potenza per la classificazione o la codifica. [14] Per quanto riguarda la scelta della finestra utilizzata nella creazione dei filtri e nell'applicazione della PSD, sono stati effettuati test su tutte le finestre messe a disposizione dalla libreria SciPy. I risultati migliori sono stati ottenuti con la finestra "flattop" per il design dei filtri e la finestra "blackman" come parametro della PSD. La versione di Python utilizzata per lo sviluppo è la 3.8, per quanto riguarda le librerie impiegate:

- Keras 2.12.0
- NumPy 1.24.3
- Pandas 1.5.3
- PyWavelets 1.4.1
- SciPy 1.10.1
- TensorFlow 2.12
- ScikitLearn 1.2.2

IV. SPERIMENTAZIONE

Le macchine usate per le computazioni hanno le seguenti caratteristiche hardware:

- Windows 10, CPU AMD Ryzen 5 2600, 16 GB RAM, GPU NVIDIA GTX 1080
- EndeavourOS (Linux 6.3), CPU AMD Ryzen 5 5600H, 16 GB RAM, GPU NVIDIA GeForce RTX 3050

A. Dataset

Il dataset impiegato in questo lavoro è il dataset BED [15]. Contiene le registrazioni EEG e le risposte di 21 persone (18 maschi e 3 femmine), acquisite sotto 12 stimoli diversi in tre sessioni. Gli stimoli si possono suddividere in 4 categorie diverse:

- stimolo affettivo: Si tratta di una serie di immagini che miravano a suscitare le tipiche risposte emotive durante l'acquisizione EEG. 48 immagini sono state suddivise in quattro set di 12 immagini ciascuno. Uno di questi set è stato selezionato a caso per essere mostrato ai partecipanti in tutte e tre le sessioni, mentre gli altri tre insieme sono stati assegnati a una sessione ciascuno. In ogni sessione, ogni soggetto vedeva prima le prime 12 immagini comuni condivise tra le sessioni, e poi le 12 immagini aggiuntive assegnate alla sessione specifica.
- stimolo cognitivo: sono stati utilizzati task cognitivi sotto forma di addizioni a due cifre. Seguendo un approccio simile a quello degli stimoli affettivi, sono stati creati in

modo casuale quattro set di 12 operazioni di addizione a due cifre. Dei quattro insiemi, uno è stato scelto a caso per essere utilizzato in tutte e tre le sessioni, mentre i restanti tre set sono stati assegnati in modo casuale a una sessione ciascuno. In ogni sessione, ai soggetti è stato prima presentato l'insieme di operazioni condiviso nelle tre sessioni, poi l'insieme di operazioni per ciascuna sessione.

- Visual Evoked Potentials (VEP): ai soggetti sono stati presentati VEP a quattro diverse frequenze, cioè 3, 5, 7 e 10 Hz. I pattern mostrati comprendevano il modello standard a scacchiera con pattern reversal, così come la VEP lampeggiante con un colore a tinta unita, settato come nero.
- stato di riposo: il protocollo consiste nel rilassamento a occhi chiusi (RC) o a occhi aperti (RO). Lo schermo davanti ai partecipanti è rimasto spento durante il protocollo di stato di riposo per evitare qualsiasi effetto sui partecipanti.

Sono stati catturati 14 canali ad una frequenza pari a 256 Hz usando l'headset Emotiv EPOC+ mostrato in Figura 2. Il dataset comprende le registrazioni EEG grezze senza preprocessing e i file di log della procedura sperimentale, in formato testuale. Le registrazioni dei segnali EEG sono state segmentate, strutturate e annotate in base agli stimoli presentati ai soggetti in formato MATLAB. Va notato che i dati EEG sono stati acquisiti in un ambiente controllato al fine di ridurre la variabilità dei dati acquisiti derivante da condizioni esterne.



Fig. 2: Emotiv EPOC+ headset




Fig. 3: Segnale EEG (1s) dal partecipante #1 (sessione #1)

[15]

B. Step sperimentazione

- Lettura segnali EEG grezzi: per poter applicare il preprocessing ai segnali, è chiaramente necessario come step fondamentale andare a leggere tali segnali. Per fare ciò, i dati disponibili in formato MATLAB sono stati letti con la libreria SciPy. Successivamente, per garantire una maggiore semplicità e ottimizzazione delle operazioni, i dati salienti vengono interpretati sotto forma di DataFrame, struttura dati principale della libreria Pandas.
- Preparazione dei dati: per ogni soggetto e sessione abbiamo suddiviso il segnale EEG completo in 66 segmenti che rappresentano tutti gli stimoli a cui è stato sottoposto il soggetto. I segnali dei 14 sensori sono stati concatenati in modo tale da ottenere il segnale EEG completo per ogni soggetto e sessione. Organizzare i dati in questo modo ci ha permesso di ottenere 66 segnali EEG per ciascuna sessione ad utente.
- Preprocessing: a ciascun segnale EEG vengono applicati due filtri FIR (Finite Impulse Response): un filtro passa-basso a 80 Hz ed un filtro passa-alto a 0.5 Hz. Al segnale filtrato viene applicata la trasformata Wavelet discreta per effettuare una decomposizione a 4 livelli del segnale. Successivamente, viene calcolata la PSD tramite la funzione Welch. Per la stima dello spettro, il periodogramma è il metodo più semplice. Questo metodo consiste nell'eseguire la trasformata discreta di Fourier (DFT) del campionamento del processo stocastico e nel calcolare il quadrato dell'ampiezza. La funzione di Welch applicata in questo lavoro è un miglioramento del periodogramma. Divide i dati in alcuni segmenti che possono sovrapporsi, quindi stima ogni segmento e fa la media. In questo caso, abbiamo impostato i parametri sovrapposizione del 25% e finestra di Blackman come parametri. Per effettuare data augmentation è stato effettuato il mirroring del segnale rispetto all'asse delle ascisse. Il mirroring consiste nel replicare e riflettere il segnale.

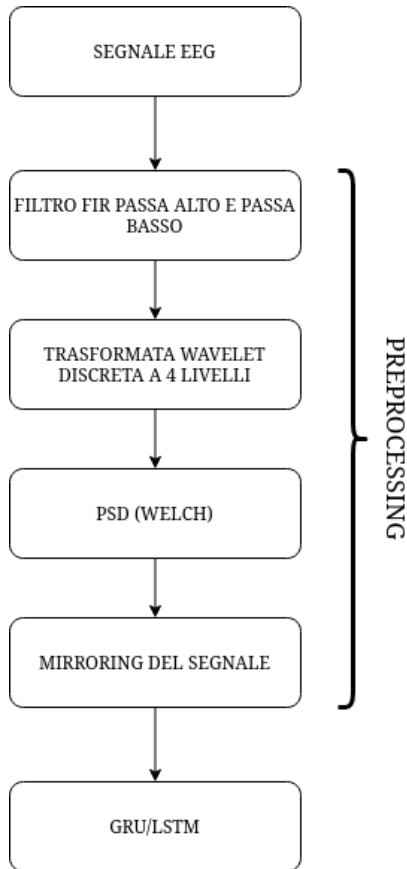
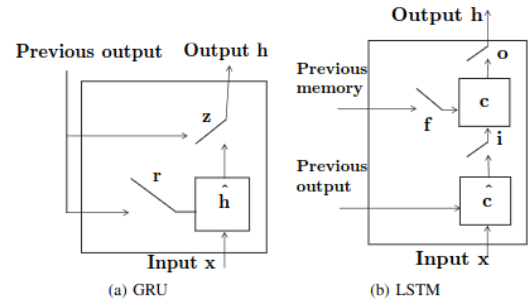


Fig. 4: Step sperimentazione

- Training modelli: il dataset per l'identificazione è stato diviso come segue: 70% per il training set e 30% per quanto riguarda il test set. Il primo modello utilizzato è un Gated Recurrent Unit (GRU) con 64 unità e un dropout rate pari a 0.2. Il primo layer è un Normalization layer. Dopodichè è stato aggiunto un Dense layer con 16 unità e ReLU come funzione di attivazione. Questo layer è seguito da un altro Dense layer composto da 21 unità, utilizzando in questo caso softmax come funzione di attivazione. Il secondo modello consiste in una Long Short Term Memory (LSTM) con 64 unità. Il dropout rate e i layer che compongono il modello sono gli stessi impiegati nell'architettura della GRU. Per effettuare l'identificazione e la verifica è stato adottato il medesimo preprocessing. Per l'identificazione il modello è stato addestrato su tutte e tre le sessioni per ciascun soggetto. Per migliorare le performance dei modelli, viene utilizzato l'early stopping per monitorare la validation loss. La differenza fondamentale tra un GRU e un LSTM è che un GRU ha due porte (porte di reset e di update), mentre un LSTM ha tre porte (cioè porte di input, di output e di forget). Rispetto alle LSTM, i modelli GRU sono più veloci da addestrare e richiedono un numero minore di dati per generalizzare, anche se presentano prestazioni e accuratezza comparabili.



C. Risultati

Per quanto riguarda l'identificazione, i risultati sono stati calcolati effettuando la media aritmetica sull'esecuzione di 11 test. I valori riportati in tabella mostrano inoltre la Precision e il Recall. La precision misura l'accuratezza del modello nel classificare un campione come positivo. Il recall misura la capacità del modello di rilevare i campioni positivi. Più alto è il recall, maggiore è il numero di campioni positivi rilevati. La tabella seguente confronta le metriche adottate tra i due modelli proposti.

	LSTM	GRU
ACC	91,70	91,34
PREC	95,10	93,60
REC	89,55	89,71

Per la verifica l'addestramento è avvenuto sulle sessioni 1 e 2, mentre è stata usata la terza sessione come test set. Le prestazioni sulla verifica sono state valutate in termini di EER e area sotto la curva (AUC). L'area sotto la curva fornisce il valore AUC nell'intervallo [0, 1]. I valori di AUC superiori a 0,6 sono considerati una "discriminazione accettabile" [19]. Le tabelle I e II mostrano i risultati della verifica effettuata prima sui singoli soggetti e poi sugli stimoli ai quali sono sottoposti. Anche in questo caso le medie sono state calcolate sulla base di 11 test.

V. DISCUSSIONE RISULTATI

I risultati prodotti dai due modelli sull'identificazione e la verifica presentano risultati molto simili. Per quanto riguarda l'identificazione l'LSTM registra un'accuratezza e una precisione leggermente superiori rispetto al GRU, nel caso del recall invece il GRU si pone in leggero vantaggio. Per ambedue i modelli è stata ottenuta un'accuratezza elevata superiore al 90%. La verifica è stata effettuata sia sui soggetti considerando tutti gli stimoli sia sui soggetti andando a considerare esclusivamente gli stimoli. In merito alla verifica, in media su AUC e EER sono stati ottenuti gli stessi risultati per entrambi i modelli. Su 21 soggetti, 17 presentano un valore AUC maggiore di 0.6 quindi potenzialmente discriminati correttamente. Se considerassimo valori di AUC maggiori di 0.9, abbiamo un totale di 8 soggetti verificati con GRU e 7 con l'LSTM. Per alcuni soggetti (come ad esempio il 14) sono stati ottenuti valori di AUC molto bassi, ciò può essere dovuto a diversi fattori:

- il soggetto potrebbe essere stato sottoposto a stimoli differenti nel corso della terza sessione, ad esempio nel caso degli stimoli visivi, il soggetto potrebbe aver subito

l'influenza di immagini che hanno suscitato emozioni differenti (foto di animali maltrattati o violazione dei diritti umani).

- poichè il recording delle sessioni è avvenuto a distanza di settimane, lo stato d'animo del partecipante potrebbe aver subito cambiamenti rispetto alle registrazioni delle sessioni precedenti.
- le condizioni fisiche (stanchezza, fame, stress etc.) del partecipante sono un fattore potenzialmente determinante per la variazione del segnale EEG.

Quindi, tutti questi fattori potrebbero rendere i segnali tra le varie sessioni scorrelati andando quindi a inficiare il valore medio dell'AUC. Relativamente alla verifica per stimoli, i risultati migliori con l'utilizzo del GRU sono stati ottenuti dallo stimolo VEP mentre i più bassi riguardano gli stimoli visivi e cognitivi (Image e Cognitive). Per l'LSTM, l'AUC maggiore è stata ottenuta con lo stimolo Closed (il partecipante era in uno stato di riposo ad occhi chiusi). L'AUC più basso è stato registrato con lo stimolo cognitivo. In ogni caso, per tutti gli stimoli è stato raggiunto un AUC superiore a 0,6.

	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10	S11	S12	S13	S14	S15	S16	S17	S18	S19	S20	S21	AVG
AUC	0,68	0,72	0,50	0,99	0,51	0,99	0,90	1,00	0,69	0,54	0,99	0,90	0,99	0,15	0,65	0,88	0,86	0,79	0,65	0,89	0,82	0,77
EER	0,32	0,28	0,50	0,01	0,49	0,01	0,10	0,00	0,31	0,46	0,01	0,10	0,01	0,85	0,35	0,22	0,24	0,21	0,35	0,11	0,18	0,23
	Image	Cognitive	VEPC	VEP	Rest	Closed	Open	AVG														
AUC	0,7	0,7	0,8	0,83	0,8	0,81	0,73	0,77														
EER	0,3	0,3	0,2	0,27	0,2	0,19	0,27	0,23														

(a) GRU

	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10	S11	S12	S13	S14	S15	S16	S17	S18	S19	S20	S21	AVG
AUC	0,68	0,62	0,44	1,00	0,49	1,00	0,94	0,97	0,85	0,37	0,97	0,95	1,00	0,08	0,69	0,89	0,86	0,84	0,72	0,89	0,94	0,77
EER	0,32	0,38	0,56	0,00	0,51	0,00	0,06	0,03	0,15	0,63	0,03	0,05	0,00	0,92	0,31	0,11	0,14	0,16	0,28	0,11	0,06	0,23
	Image	Cognitive	VEPC	VEP	Rest	Closed	Open	AVG														
AUC	0,7	0,68	0,81	0,81	0,81	0,82	0,80	0,77														
EER	0,3	0,22	0,19	0,18	0,19	0,18	0,20	0,23														

(b) LSTM

VI. CONCLUSIONI

In questo lavoro, è stato utilizzato il dataset BED, composto dai segnali EEG catturati da 21 diversi soggetti sottoposti a 12 stimoli differenti su 3 sessioni. I risultati sono stati valutati in due contesti tipici della biometrica come l'identificazione e la verifica. Il preprocessing eseguito sui segnali EEG è necessario per rimuovere rumore o artefatti ed è lo stesso per entrambi gli scenari e consiste nell'applicazione di due filtri FIR (passa-basso e passa-alto), trasformata Wavelet discreta, calcolo della densità spettrale di potenza e infine mirroring del segnale risultante. Per quanto concerne l'identificazione i risultati leggermente migliori sono stati ottenuti utilizzando una LSTM come architettura della rete. Nel contesto della verifica i risultati mostrati sono praticamente simili. Eventuali lavori futuri potrebbero sfruttare i risultati ottenuti in questo lavoro per ridurre la mole di dati utilizzata per il preprocessing ad esempio andando a considerare determinati stimoli anziché tutti quelli presentati all'interno del dataset. Oppure non considerando i soggetti che presentano una forte scorrelazione dei segnali EEG tra le sessioni. Per migliorare le metriche, inoltre, si potrebbero adottare modelli differenti o impostare un'architettura a cascata di più modelli. Inoltre, non è da escludere la possibilità di utilizzare un altro dataset sfruttando il preprocessing proposto in questo lavoro.

REFERENCES

- [1] A survey on methods and challenges in EEG based authentication Amir Jalaly Bidgoly, Hamed Jalaly Bidgoly, Zeynab Arezoumand
- [2] Sanei, S., Chambers, J., 2013. EEG Signal Processing. Wiley.
- [3] Niedermeyer, E., da Silva, F.L., 2005. Electroencephalography: Basic Principles, Clinical Applications, and Related Fields. Lippincott Williams and Wilkins.
- [4] Du, Y., Xu, Y., Wang, X. et al. EEG temporal-spatial transformer for person identification. *Sci Rep* 12, 14378 (2022). <https://doi.org/10.1038/s41598-022-18502-3>
- [5] Jalaly Bidgoly, A., Jalaly Bidgoly, H. & Arezoumand, Z. A survey on methods and challenges in eeg based authentication. *Comput. Secur.* 101788 (2020).
- [6] Sun, Y., Lo, F. P. & Lo, B. EEG-based user identification system using 1D-convolutional long short-term memory neural networks. *Expert Syst. Appl.* 125, 259–267 (2019).
- [7] Wang, M., El-Fiqi, H., Hu, J. & Abbass, H. A. Convolutional neural networks using dynamic functional connectivity for eeg-based person identification in diverse human states. *IEEE Trans. Inf. Forensics Secur.* 14, 3259–3272 (2019).
- [8] Wilaiprasitporn, T. et al. Affective eeg-based person identification using the deep learning approach. *IEEE Trans. Cognit. Dev. Syst.* (2019).
- [9] Singh, B., Mishra, S. & Tiwary, U. S. Eeg based biometric identification with reduced number of channels. In 2015 17th International Conference on Advanced Communication Technology (ICACT), 687–691 (2015).
- [10] Kaur, B. & Singh, D. Neuro signals: A future biomertic approach towards user identification. In 2017 7th International Conference on Cloud Computing, Data Science Engineering—Confluence, 112–117 (2017).
- [11] Fraschini, M., Hillebrand, A., Demuru, M., Didaci, L. & Marcialis, G. L. An eeg-based biometric system using eigenvector centrality in resting state brain networks. *IEEE Signal Process. Lett.* 22, 666–670 (2015).
- [12] Q. Gui, M. V. Ruiz-Blondet, S. Laszlo, and Z. Jin, “A survey on brain biometrics,” *ACM Computing Surveys*, vol. 51, no. 6, pp. 1–38, 2019.
- [13] Review on EEG-Based Authentication Technology, Shuai Zhang, Lei Sun, Xiuqing Mao, Cuiyun Hu, and Peiyuan Liu
- [14] K. P. Thomas and A. P. Vinod, “EEG-based biometric authentication using gamma band power during rest state,” *Circuits, Systems, and Signal Processing*, vol. 37, no. 1, pp. 277–289, 2018.
- [15] BED: A New Data Set for EEG-Based Biometrics Pablo Arnau-González, Stamos Katsigiannis, Member, IEEE, Miguel Arevalillo-Herráez, and Naeem Ramzan, Senior Member, IEEE
- [16] Wolfgang Klimesch, Memory processes, brain oscillations and EEG synchronization, *International Journal of Psychophysiology*
- [17] Zhang, Y., Chen, Y., Bressler, S.L., Ding, M., 2008. Response preparation and inhibition: the role of the cortical sensorimotor beta rhythm. *Neuroscience* 156 (1), 238–246.
- [18] Read, G.L., Innis, I.J., 2017. Electroencephalography (EEG). *Am. Cancer Soc.*, pp. 1–18.
- [19] Gorur, K., Olmez, E., Ozer, Z. et al. EEG-Driven Biometric Authentication for Investigation of Fourier Synchrosqueezed Transform-ICA Robust Framework. *Arab J Sci Eng* (2023). <https://doi.org/10.1007/s13369-023-07798-6>